

Lab02_marreiro

Fernanda Marreiro

LAB02: Processamento de Bases de Dados em Lote

1. Quais são as estatísticas suficientes para a determinação do percentual de vôos atrasados na chegada (`ARRIVAL_DELAY > 10`)?

```
## As estatísticas suficientes são  
## a) número total de voos (para cada combinação dia/mes/cia)  
## b) número de voos (dentro dos apontados acima) que tem a coluna  
arrival_delay > 10
```

2. Crie uma função chamada `getStats` que, para um conjunto de qualquer tamanho de dados provenientes de `flights.csv.zip`, execute as seguintes tarefas (usando apenas verbos do `dplyr`):
 - a. Filtre o conjunto de dados de forma que contenha apenas observações das seguintes Cias. Aéreas: AA, DL, UA e US;
 - b. Remova observações que tenham valores faltantes em campos de interesse;
 - c. Agrupe o conjunto de dados resultante de acordo com: dia, mês e cia. aérea;
 - d. Para cada grupo em b., determine as estatísticas suficientes apontadas no item 1. e os retorne como um objeto da classe `tibble`;
 - e. A função deve receber apenas dois argumentos:
 - i. `input`: o conjunto de dados (referente ao lote em questão);
 - ii. `pos`: argumento de posicionamento de ponteiro dentro da base de dados. Apesar de existir na função, este argumento não será empregado internamente. **É importante** observar que, sem a definição deste argumento, será impossível fazer a leitura por partes.

```
library(dplyr)
```

```
Attaching package: 'dplyr'
```

```
The following objects are masked from 'package:stats':
```

```
filter, lag
```

The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```
getStats = function(input, pos){
  input %>%
    filter(AIRLINE %in% c('AA', 'DL', 'UA', 'US'), !is.na(ARRIVAL_DELAY)) %>%
    group_by(AIRLINE, DAY, MONTH) %>%
    summarise(n=n(), atrasos=sum(ARRIVAL_DELAY > 10))
}
```

3. Utilize alguma função `readr::read_***_chunked` para importar o arquivo `flights.csv.zip`.
 - a. Configure o tamanho do lote (chunk) para 100 mil registros;
 - b. Configure a função de *callback* para instanciar DataFrames aplicando a função `getStats` criada acima;
 - c. Configure o argumento `col_types` de forma que ele leia, diretamente do arquivo, apenas as colunas de interesse (veja nota de aula para identificar como realizar esta tarefa);

```
library(readr)

library(tictoc)

in3 = read_csv_chunked(
  'flights.csv',
  chunk_size = 10000,
  callback = DataFrameCallback$new(getStats),
  col_types = cols_only(AIRLINE='c', DAY='i', MONTH='i', ARRIVAL_DELAY='i')
)
```

```
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
`summarise()` has regrouped the output.
```


- b. Retorne as informações em um tibble contendo apenas as seguintes colunas:
 - i. Cia: sigla da companhia aérea;
 - ii. Data: data, no formato AAAA-MM-DD (dica: utilize o comando `as.Date()`);
 - iii. Perc: percentual de atraso para aquela cia. aérea e data, apresentado como um número real no intervalo $[0, 1]$.

```
computeStats = function(input){
  input %>% group_by(AIRLINE, DAY, MONTH) %>%
    summarise(Perc = sum(atrasos)/sum(n)) %>%
    ungroup() %>%
    mutate(Data = as.Date(paste(2015, MONTH, DAY, sep='-'))) %>%
    select(AIRLINE, Data, Perc)
}

in5 = in3 %>% computeStats()
```

```
`summarise()` has regrouped the output.
i Summaries were computed grouped by AIRLINE, DAY, and MONTH.
i Output is grouped by AIRLINE and DAY.
i Use `summarise(groups = "drop_last")` to silence this message.
i Use `summarise(.by = c(AIRLINE, DAY, MONTH))` for per-operation grouping
  (`?dplyr::dplyr_by`) instead.
```


5. Produza um mapa de calor em formato de calendário para cada Cia. Aérea.
 - a. Instale e carregue os pacotes `ggcal` e `ggplot2`.
 - b. Defina uma paleta de cores em modo gradiente. Utilize o comando `scale_fill_gradient`. A cor inicial da paleta deve ser `#4575b4` e a cor final, `#d73027`. A paleta deve ser armazenada no objeto `pal`.
 - c. Crie uma função chamada `baseCalendario` que recebe 2 argumentos a seguir: `stats` (tibble com resultados calculados na questão 4) e `cia` (sigla da Cia. Aérea de interesse). A função deverá:
 - i. Criar um subconjunto de `stats` de forma a conter informações de atraso e data apenas da Cia. Aérea dada por `cia`.
 - ii. Para o subconjunto acima, montar a base do calendário, utilizando `ggcal(x, y)`. Nesta notação, `x` representa as datas de interesse e `y`, os percentuais de atraso para as datas descritas em `x`.
 - iii. Retornar para o usuário a base do calendário criada acima.
 - d. Executar a função `baseCalendario` para cada uma das Cias. Aéreas e armazenar os resultados, respectivamente, nas variáveis: `CAA`, `cDL`, `CUA` e `cUS`.
 - e. Para cada uma das Cias. Aéreas, apresente o mapa de calor respectivo utilizando a combinação de camadas do `ggplot2`. Lembre-se de adicionar um título utilizando o comando `ggtitle`. Por exemplo, `cXX + pal + ggtitle("Titulo")`.

```

library(ggcal)
library(ggplot2)
pal = scale_fill_gradient(low = '#4575b4', high = '#d73027')
baseCalendario = function(stats, cia){
  input = stats %>% filter(AIRLINE==cia)
  ggcal(input$Data, input$Perc)
}
cAA = baseCalendario(in5, 'AA')
cDL = baseCalendario(in5, 'DL')
cUA = baseCalendario(in5, 'UA')
cUS = baseCalendario(in5, 'US')
cAA + pal + ggtitle("American Airlines")

```

American Airlines




```

cDL + pal + ggtitle("Delta Airlines")


```


Delta Airlines




```
cUA + pal + ggtitle("United Airlines")
```

United Airlines



```
cUS + pal + ggtitle("US Airways")
```

US Airways



```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-24 16:45:58 -03"
```