

# Lab03\_marreiro

AUTHOR

Fernanda Marreiro

## Lab03: Dados relacionais e operações do tipo *join*

---

### Objetivos:

- em ambas as tabelas;
- apenas na primeira tabela;
- apenas na segunda tabela;
- em alguma das duas tabelas.

### Carregue os pacotes relevantes para este Laboratório

```
library(readr)
library(dplyr)
library(stringr)
library(tidyr)
library(magrittr)
```

### 1. Importando `airlines` e `airports`

```
# Importando todo o arquivo de companhias aéreas
airlines <- read_csv("airlines.csv")

# Importando apenas as colunas de aeroportos
airports <- read_csv(
  "airports.csv",
  col_select = c(IATA_CODE, CITY, STATE, LATITUDE, LONGITUDE)
)
```

### Para o arquivo de vôos:

1. Importe apenas as colunas `DESTINATION_AIRPORT` e `ARRIVAL_DELAY`;
2. Leia apenas 1 milhão de linhas por vez;
3. Remova vôos em que o aeroporto de destino comece com a letra 1;
4. Remova registros em que existam pelo menos uma coluna faltante;
5. Determine, para cada parte do arquivo, as estatísticas suficientes para a determinação do atraso médio por aeroporto de destino;
6. Ao finalizar a leitura do arquivo, combine as estatísticas suficientes de modo a produzir a média de atraso por aeroporto.

```
# 1.Processamento por bloco
processa_bloco <- function(chunk, index) {
  chunk %>%
    drop_na(DESTINATION_AIRPORT, ARRIVAL_DELAY) %>%
    filter(!str_starts(DESTINATION_AIRPORT, "1")) %>%
    group_by(DESTINATION_AIRPORT) %>%
    summarize(
      soma_atraso = sum(ARRIVAL_DELAY),
      total_voos = n(),
      .groups = "drop"
    )
}

# 2. Leitura em lotes filtrando as colunas
estatisticas_acumuladas <- read_csv_chunked(
  file = "flights.csv",
  callback = DataFrameCallback$new(processa_bloco),
  chunk_size = 1000000,
  col_types = cols_only(
    DESTINATION_AIRPORT = col_character(),
    ARRIVAL_DELAY = col_double()
  )
)

# 3. média de atraso no objeto 'flights'
flights <- estatisticas_acumuladas %>%
  group_by(DESTINATION_AIRPORT) %>%
  summarize(
    media_atraso = sum(soma_atraso) / sum(total_voos),
    .groups = "drop"
  )
```

2. Selecione a operação apropriada *join* para incluir, na tabela `flights`, as colunas `CITY` e `STATE` do objeto `airports`.

1. Identifique a coluna que é a chave na tabela `flights`;
2. Identifique a coluna que é a chave na tabela `airports`;
3. Quais são os aeroportos que estão listados em `flights`, mas estão ausentes em `airports`?
4. Apresente o comando que combine ambas as tabelas, indicando explicitamente as chaves;
5. Armazene a tabela resultante no objeto `flights`.

```
## chave em flights: DESTINATION_AIRPORT
## chave em airports: IATA_CODE

# 3. Identifica aeroportos ausentes (exibindo apenas os códigos únicos)
flights %>%
  anti_join(airports, by = c('DESTINATION_AIRPORT' = 'IATA_CODE')) %>%
  select(DESTINATION_AIRPORT) %>%
  distinct()
```

```
# A tibble: 0 × 1
# i 1 variable: DESTINATION_AIRPORT <chr>
```

```
# Junta as tabelas mantendo as coordenadas e dados geográficos
flights <- flights %>%
  left_join(airports, by = c("DESTINATION_AIRPORT" = "IATA_CODE")) %>%
  filter(!is.na(LATITUDE), !is.na(LONGITUDE)) # remove aeroportos sem coordenadas válidas
```

3. Quantos aeroportos cada estado possui? Apresente uma tabela ordenada de forma decrescente (no número de aeroportos).

```
# Agrupa por estado, conta o total de aeroportos e ordena do maior para o menor
tabela_aeroportos_estado <- airports %>%
  count(STATE, name = "total_aeroportos", sort = TRUE)

tabela_aeroportos_estado
```

```
# A tibble: 54 × 2
  STATE total_aeroportos
  <chr>          <int>
1 TX              24
2 CA              22
3 AK              19
4 FL              17
5 MI              15
6 NY              14
7 CO              10
8 MN               8
9 MT               8
10 NC              8
# i 44 more rows
```

4. Apresente um mapa representando todos os atrasos observados por aeroporto.

1. Carregue o pacote `leaflet`;
2. Combine os comandos `leaflet`, `addTiles` e `addMarkers` para a criação de um mapa básico;
3. Armazene o grafico em b) numa variável chamada `this`;

```
library(leaflet)

# Criação do mapa e armazenamento na variável 'this'
this <- leaflet(flights) %>%
  addTiles() %>%
  addCircleMarkers(
    lng = ~LONGITUDE,
    lat = ~LATITUDE,
    radius = ~pmax(media_atraso, 2), # pmax previne raios zerados/negativos
    popup = ~paste0("<b>Aeroporto: </b>", DESTINATION_AIRPORT, "<br>",
                    "<b>Cidade: </b>", CITY, " - ", STATE, "<br>",
                    "<b>Atraso médio: </b>", round(media_atraso, 1), " min"),
```

```


label = ~as.character(DESTINATION_AIRPORT),
fillOpacity = 0.6,
color = ~ifelse(media_atraso < 10, "navy", "red"),
clusterOptions = markerClusterOptions()
)

```

```

# Renderiza o mapa
this

```



```

Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()

```

```
[1] "2026-08-31 17:46:52 -03"
```